

# 基于 CNN 的无人驾驶行人识别

张芝衍(西安市曲江第一中学,陕西省 西安市 710061)

**【摘要】**无人驾驶中行人识别的精度是影响车辆安全的重要因素,传统的无人驾驶行人识别采用基于统计分类的方法,该方法在精度和灵活性上具有一定的缺陷。行人识别的根本是对图像的识别,卷积神经网络是一种针对图像分类、识别而发展的深度学习算法,其强大的图像分类识别能力被广泛应用在图像分类系统中,取得了不错的效果。因此,本文将卷积神经网络算法应用于无人驾驶行人识别中,前期使用 PCA 算法对图像数据进行降维,以减少卷积神经网络算法运算复杂度。本文采用 KITTI 数据集进行仿真,实验表明,基于神经网络的无人驾驶行人识别精度相对于其他统计分类算法精度高。

**【关键词】**无人驾驶;行人识别;PCA;卷积神经网络

**【中图分类号】**TP391.4

**【文献标识码】**A

**【文章编号】**1006-4222(2019)05-0246-02

## 1 引言

汽车的发明和使用大大便利了人们的出行,提升了生活质量。然而,随着车辆的增多,交通事故发生率在不断提高,很大一部分原因是司机自身原因造成的,如醉驾、疲劳驾驶等原因导致未能及时发现行人,我国每年死于交通事故的就有几万人。为了实现更智能、更安全的驾驶,国内外开始研究无人驾驶技术,其中,行人检测是无人驾驶辅助系统必不可少的一部分,通过智能的识别行人,可以在事故发生前采取紧急制动,避免交通事故的发生。

行人检测的研究已经开展了几十年,无论是检测精度还是检测速度都取得了较大的进展,然而行人检测技术难度较高,受自然环境的多样和复杂性、各种拍摄角度及光线、人体不同拍摄姿态、多种服饰打扮等多种因素的影响,所以,行人检测技术还处于探索阶段。目前,基于统计分类的方法是行人检测技术的主流,将测试对象分为人与非人两类,通过特征提取提取到目标特征,通过分类学习将目标进行分类<sup>[1]</sup>。传统的行人检测方法需要认为构建特征,此方法无论在灵活性还是在稳定性上都有一定限制。在 2005 年提出的梯度方向直方图(HOG)特征<sup>[2]</sup>是目前最具有泛化能力的特征之一,在行人分类上取得了较好的效果,HOG 特征大大推进了行人检测技术的发展,此后大部分行人检测的文章是在此基础上拓展的,然而该方法在背景复杂及有遮挡等情况下,检测效率较差。最近,深度学习成为研究的热点,该技术通过自动的学习数据特征,避免复杂的数据特征提取,且在检测准确率上优于传统检测技术<sup>[3-4]</sup>。

卷积神经网络是深度学习的一种算法,卷积神经网络具有自学习、权值共享的特点,其中权值共享可以减少网络连接参数,将权值共享与下采样、局部连接方法结合,使得它在图像识别领域占有优势。本文将卷积神经网络算法应用在无人驾驶中的行人识别,实验证明,该方法在行人检测方面的精度较高。

## 2 行人识别过程

### 2.1 行人识别框架

本文的行人识别流程如图 1 所示,行人视频切分成帧,对视频帧进行主成分分析 PCA 方法进行降维,将降维后的图像输入到卷积神经网络中,得到行人的分类结果。

### 2.2 CNN 实现过程

实现 CNN 在行人检测的功能主要分为训练和测试两个阶段,训练阶段包括对数据集进行特征提取并分类,测试阶段对输入数据进行判别,两阶段如图 2 所示。

测试阶段根据测试数据集、目标函数,不断的优化模型的参数,得到符合要求的模型;测试阶段将测试数据集过训练好



图1 行人识别流程图



图2 CNN 实现过程

的模型,得到判别结果。本文中,数据集是道路行人数据集,得到的判别结果行人的类别。

## 3 行人识别算法

### 3.1 主成分分析

主成分分析算法简称 PCA,其基本思想是将  $n$  维特征映射到  $k$  维空间上,其中,  $k < n$ ,将有相关性的  $n$  维数据映射为无相关性的  $k$  维数据,从而达到降维的目的。PCA 算法示例如图 3 所示。




图3 PCA 算法示例

原始数据点用三角形表示,圆点是第一主成分绘制出来

的结果,第一主成分占据了原始数据中最重要的消息,将原始三角形数据映射到圆点数据上,可以降低数据的维度。PCA 算法的步骤如下所示:

设有  $m$  条  $n$  维数据。

步骤 1:将原始数据组成  $m$  行  $n$  列矩阵,命名为  $X$ ;

步骤 2:将矩阵  $X$  的每一行进行标准化处理,即数值减去均值的结果除标准差;

步骤 3:设协方差矩阵为  $C$ ,计算协方差矩阵  $C = \frac{1}{m}XX^T$ ;

步骤 4:求解协方差矩阵  $C$  的特征值  $A$  及对应的特征向量  $B$ ;

步骤 5:将特征值按照从大到小的顺序进行排列,取占比较高  $K$  几个特征值作为主成分,将其对应的  $K$  个特征向量组成矩阵  $P$ ;

步骤 6:计算  $Y=PX$ ,即  $Y$  为  $X$  降维到  $k$  维后的数据。

### 3.2 神经网络结构

神经网络是一种监督学习算法,由输入层、卷积层、池化层、全连接层、输出层组成,神经网络结构如图 4 所示。




图 4 神经网络结构

其中,卷积层用于提取特征,池化层用于数据降维,激活函数将原始数据映射到非线性空间,全连接层连接所有特征,经 Softmax 层进行分类。其中:

输入层是整个神经网络的输入,本文中输入的数据是经过 PCA 算法降维后的数据。

卷积层是神经网络中最重要的部分,卷积层用于提取特征,通过梯度下降反向传播的方法得到每个卷积单元的参数,卷积神经网络的第一层可能用于提取一些简单的特征,多个卷积层就可以从低级特征迭代提取到更加复杂的特征。

池化层:即下采样,在卷积层之后紧跟池化层,卷积层的特征面与池化层的特征面对应,池化层的目的是通过降低特征面的分辨率来减少特征图。

全连接层:该层的每个神经元与上层的所有神经元相连,综合前面提取到的特征,整合其他层中的局部信息。

Softmax 层:该层将全连接层输出的消息经过 Softmax 分类层,得到输出的具体指令。

#### 3.2.1 损失函数

卷积神经网络经过 Softmax 层输出指令后,得到计算值与实际值之间的差距,即损失函数:

$$C = -\frac{1}{n} [y \ln a - (1-y) \ln (1-a)]$$

损失函数是神经网络优化的目标,损失函数越小,意味着计算值与实际值越接近。

#### 3.2.2 梯度下降

最小化损失函数,需要将 CNN 的权值进行更新,一般情况下,使用梯度下降法进行更新,梯度下降法通过求导寻找当前位置下降最快的方向和大小。梯度下降法的公式如下所示:

$$\frac{df(x)}{dx} = \lim_{h \rightarrow 0} \frac{f(x+h) - f(x)}{h}$$

## 4 具体实现效果

### 4.1 数据来源

本文使用的数据源是 KITTI 数据集,该数据集是真实自动驾驶场景下目前国际上最大的计算机视觉测试数据集,主

要用于评测立体图像、3D 物体检测、行人是被等计算机视觉在无人驾驶下的性能,数据集来源于市区、乡村、高速公路等真实场景,数据集中图片最多包含 15 辆车和 30 个行人,为保证图片的真实性,图片还有不同程度的截断和遮挡,总体上看,原始数据集被分类为 'Road', 'City', 'Residential', 'Campus' 和 'Person'。

### 4.2 性能评价及结果

为评价本文方法的性能,使用准确率 TPR、误检率 FPR 和平均时耗 ADT 三个性能指标进行评级,其中 TPR、FPR 定义如下:

$$TPR = \frac{\text{正确检测行人人数}}{\text{标记行人总数}} \times 100\%$$

$$FPR = \frac{\text{错误检测行人人数}}{\text{错误检测行人人数} + \text{正确检测行人人数}} \times 100\%$$

将该方法同 HOG-SVM<sup>[5]</sup>、LDCF<sup>[2]</sup>方法进行对比,得到的对比结果如表 1 所示。

表 1 对比结果

算法	TPR	FPR	ADT(ms)
HOG+SVM	77.9	12.1	819
LDCF	65%	35%	726
CNN	85.6%	14.4%	804

从表 1 中,我们可以得到 CNN 算法得到的准确率相对其他算法高,三种算法平均耗时相差不大。因此,可以得出,CNN 算法在保证短时延的情况下,具有更高的准确率。

## 5 总结

行人识别是无人驾驶中很重要的一部分,对安全的无人驾驶具有重要意义。目前研究无人驾驶的算法效率及精度较低,因此,本文研究深度学习中的卷积神经网络对行人识别的性能。首先,使用 PCA 方法对行人视频帧进行降维,将降维后的数据输入训练好的 CNN 模型中,得到最终的输出结果;其次,研究 CNN 实现的过程,分为训练阶段和测试阶段;再次,研究 PCA 算法的原理及实现步骤,研究卷积神经网络结构及各层的意义和作用,CNN 算法的目标函数是损失函数,最小化损失函数的方法本文采用的梯度下降法;最后,本文使用 KITTI 数据集作为本文的数据集,使用准确率 FPR、漏检率 TPR、平均时耗 AD 作为性能指标,并将 CNN 算法与 HOG+SVM、LDCF 进行比较,可以得到,CNN 算法在保证低延时的情况下,具有较高的准确率,较低的误检率。

### 参考文献

- [1] 芮挺,费建超,周游,等.基于深度卷积神经网络的行人检测[J].计算机工程与应用唯一官方网站,2016,52(13):162-166.
- [2] Dalal N, Triggs B. Histograms of Oriented Gradients for Human Detection[C]. IEEE Computer Society, 2005.
- [3] 张泽轩,陈虎,吴志红,等.基于深度学习的道路实景行人车辆检测[J].现代计算机:专业版,2018, No.610(10):34-38.
- [4] Mateus A, Ribeiro D, Miraldo P, et al. Efficient and Robust Pedestrian Detection using Deep Learning for Human-Aware Navigation[J]. 2016.
- [5] P. Yadav R, Senthilarasu V, Kutty K, et al. Implementation of Robust HOG-SVM based Pedestrian Classification[J]. International Journal of Computer Applications, 2015, 114(19):10-16.
- [6] Ma Z, Gao P P. [IEEE 2018 IEEE International Conference on Big Data and Smart Computing (BigComp) - Shanghai, China (2018.1.15-2018.1.17)] 2018 IEEE International Conference on Big Data and Smart Computing (BigComp) - Research on the Cascade Pedestrian Detection Model Based on LDCF and CNN [C]. IEEE International Conference on Big Data & Smart Computing. IEEE Computer Society, 2018:314-320.

收稿日期:2019-4-20